



Управление данными и искусственный интеллект

Лекция по дисциплине:

“Глубокое обучение в компьютерном зрении”



Российский университет
дружбы народов

КОМПЛЕКСНЫЕ МЕТОДЫ СЕГМЕНТАЦИИ ИЗОБРАЖЕНИЙ: ФУНКЦИИ ПОТЕРЬ, АРХИТЕКТУРЫ И МНОГОЗАДАЧНОЕ ОБУЧЕНИЕ

Преподаватели: Перчихин Олег Игоревич
Федоренко Анастасия Олеговна

ОПРЕДЕЛЕНИЕ ЗАДАЧИ СЕГМЕНТАЦИИ

Сегментация изображений — это ключевая задача компьютерного зрения, направленная на **разделение изображения на однородные области, соответствующие различным объектам или поверхностям сцены.**

В ходе сегментации каждому пикселю изображения присваивается определённая метка, указывающая, к какому классу или области он принадлежит. Такой подход позволяет перейти от «сырых» пиксельных данных к структурированному представлению изображения, более удобному для анализа и интерпретации.

Главная цель сегментации состоит в **упорядочивании визуальной информации.** Алгоритм не рассматривает изображение как набор независимых пикселей, а объединяет их в осмысленные регионы, отражающие реальные элементы сцены. Это упрощает восприятие и делает изображение пригодным для последующих этапов обработки — распознавания, анализа или принятия решений.

В контексте сегментации существует важное концептуальное разделение:

- **Объекты (*Things*)** — отдельные, исчисляемые сущности с чёткими границами, например автомобили, люди, животные или здания.
- **Фон и текстуры (*Stuff*)** — непрерывные области без строгих границ, такие как небо, дорога, трава или вода.

ВЫХОДНЫЕ МАСКИ СЕГМЕНТАЦИИ

В процессе сегментации модель преобразует входное изображение (например, размером $800 \times 600 \times 3$, где три канала соответствуют RGB) в **многоканальную карту классов** размером $800 \times 600 \times N$, где N — количество распознаваемых категорий. Каждому пикселю изображения присваивается метка (целое число), обозначающая, к какому классу он принадлежит. Таким образом, модель формирует **карту сцены**, где каждый цвет или индекс соответствует определённому объекту или типу поверхности.

800x600x3



Input

segmented

- 1: Person
- 2: Purse
- 3: Plants/Grass
- 4: Sidewalk
- 5: Building/Structures

800x600x5

3	3	3	3	3	3	3	3	3	3	3	3	3	5	5	5	5	5	5
3	3	3	3	3	3	3	3	3	3	3	3	3	5	5	5	5	5	5
3	3	3	3	3	3	1	1	3	3	3	3	3	5	5	5	5	5	5
3	3	3	3	3	1	1	1	1	3	3	3	5	5	5	5	5	5	5
3	3	3	3	3	3	1	1	3	3	3	5	5	5	5	5	5	5	5
5	5	3	3	3	3	1	1	3	3	5	5	5	5	5	5	5	5	5
4	4	3	4	1	1	1	1	1	1	4	4	4	5	5	5	5	5	5
4	4	3	4	1	1	1	1	1	1	4	4	4	4	4	5	5	5	5
4	4	4	1	1	1	1	1	1	1	1	4	4	4	4	4	4	4	4
3	3	3	1	1	1	1	1	1	1	1	4	4	4	4	4	4	4	4
3	3	3	1	2	2	1	1	1	1	1	4	4	4	4	4	4	4	4
3	3	3	1	2	2	1	1	1	1	1	4	4	4	4	4	4	4	4


Semantic Labels



Российский университет
дружбы народов

ВЫХОДНЫЕ МАСКИ СЕГМЕНТАЦИИ

На рисунке показаны отдельные каналы для классов:
Person, Purse, Plants/Grass, Sidewalk, Building/Structures — каждый из которых соответствует своей бинарной маске в составе общей выходной карты модели.



СЕМАНТИЧЕСКАЯ СЕГМЕНТАЦИЯ

Семантическая сегментация — это метод, при котором каждому пикселю изображения присваивается **метка класса** (например, дорога, небо, человек, здание). Таким образом, модель определяет, к какой категории относится каждая точка изображения, формируя непрерывную карту классов, описывающую содержимое сцены.

Ключевая особенность


Семантическая сегментация **не различает отдельные объекты внутри одного класса**. Все элементы, принадлежащие к одной категории (например, все автомобили или все люди), отображаются как единая область. Если на изображении присутствуют три автомобиля, они будут объединены в одну маску класса «автомобиль».

Преимущества подхода

- Высокая скорость работы благодаря одному проходу по сети
- Простота обучения и интерпретации результатов
- Эффективность при большом количестве классов типа *stuff* (фон, текстуры)
- Низкие требования к вычислительным ресурсам

Ограничения метода

- Невозможно подсчитать количество отдельных объектов
- Отсутствует информация о границах между экземплярами
- Затруднено отслеживание и идентификация объектов
- Возникают ошибки при перекрывающихся объектах



СЕГМЕНТАЦИЯ ЭКЗЕМПЛЯРОВ

Сегментация экземпляров (instance segmentation) решает более сложную задачу, чем семантическая сегментация. Если при семантической сегментации каждому пикселю изображения присваивается метка класса (например, человек, автомобиль, дорога), то сегментация экземпляров дополнительно разделяет **отдельные объекты внутри одного класса**, присваивая каждому из них собственную маску и уникальный идентификатор.



Обнаружение объектов

Первый этап — детекция bounding boxes вокруг потенциальных объектов с использованием Region Proposal Networks или anchor-based методов




Классификация

Определение класса каждого обнаруженного объекта с присвоением вероятностной оценки принадлежности к категории



Формирование масок

Создание попиксельной маски для каждого объекта, точно очерчивающей его контуры и форму



ПАНОПТИЧЕСКАЯ СЕГМЕНТАЦИЯ

Паноптическая сегментация представляет собой унифицированный подход, объединяющий достоинства семантической и сегментации экземпляров. Её цель — обеспечить целостное, непротиворечивое описание всей сцены, где каждый пиксель изображения **получает и метку класса, и при необходимости уникальный идентификатор объекта**. Термин паноптическая (от греч. pan — всё, optic — видеть) отражает стремление метода к полному охвату и пониманию визуальной информации.



Унифицированное представление

Каждому пикселю присваивается не только **метка класса**, но и **уникальный идентификатор объекта** (если это «thing»). Для пикселей категории «stuff» идентификатор остаётся общим для всей области.



Полное понимание сцены

Паноптическая сегментация обеспечивает **исчерпывающее описание изображения**: все «things» (объекты) выделены индивидуально, весь «stuff» (фон) классифицирован, нет незамеченных пикселей.



Разрешение конфликтов

При пересечении или наложении пикселей **приоритет отдаётся объектам (things)** над фоном (stuff). Это решает проблему неоднозначности и обеспечивает консистентность разметки.



ПАНОПТИЧЕСКАЯ СЕГМЕНТАЦИЯ

Математическая формулировка

Паноптическая сегментация формально определяется как разбиение изображения на непересекающиеся сегменты, где:

$$PQ = \frac{\sum_{(p,g) \in TP} IoU(p,g)}{|TP| + \frac{1}{2}|FP| + \frac{1}{2}|FN|}$$

где **TP** — true positives (правильно сопоставленные сегменты), **FP** — false positives (лишние предсказания), **FN** — false negatives (пропущенные сегменты), а **IoU** — Intersection over Union.

Метрика PQ разлагается на два компонента:

- **Segmentation Quality (SQ)** — качество сегментации совпавших сегментов
- **Recognition Quality (RQ)** — качество распознавания (F1-score на уровне сегментов)

$$SQ = \frac{\sum IoU(p,g)}{|TP|}$$

$$RQ = \frac{|TP|}{|TP| + \frac{1}{2}|FP| + \frac{1}{2}|FN|}$$

Такое разложение позволяет отдельно анализировать ошибки локализации и ошибки классификации.

КЛАССИЧЕСКИЕ АРХИТЕКТУРЫ СЕГМЕНТАЦИИ

Архитектура U-Net для задач сегментации изображений, отражающей два основных этапа обработки: кодирование и декодирование.

1. Кодировущая часть (Encoder)

На каждом уровне размер карты признаков уменьшается вдвое, а число каналов увеличивается. Эта часть извлекает высокоуровневые признаки и контекст изображения, постепенно обобщая информацию.


2. Декодировущая часть (Decoder)

Симметрична энкодеру и выполняет постепенное восстановление пространственного разрешения. Каждый шаг включает **транспонированную свёртку** (Up-Conv 2x2), объединение с соответствующим уровнем энкодера через **skip-connection** и последующие свёртки. Эта часть восстанавливает точное расположение объектов и детали формы.

3. Завершающий слой

Применяется свёртка 1x1, которая преобразует выход сети в требуемое число каналов (по числу классов).

U-Net




SKIP CONNECTIONS

Во время сжатия изображения в энкодере теряется часть пространственной информации: мелкие детали, границы и контуры становятся размытыми. Чтобы восстановить их на этапе декодирования, выходы соответствующих слоёв энкодера напрямую передаются в декодер. Эти соединения позволяют объединить **глобальные признаки** (из глубоких слоёв) с **локальными деталями** (из ранних слоёв), что существенно повышает точность восстановления формы объектов.

Разметка



Без skip connections



Со skip connections



ПОВЫШЕНИЕ РАЗРЕШЕНИЯ: МЕТОД БЛИЖАЙШЕГО СОСЕДА

На этапе декодирования U-Net необходимо **увеличить размер карт признаков**, чтобы постепенно вернуться от «сжатого» представления к исходному разрешению изображения. Для этого применяется операция **upsampling**, и один из способов её реализации - **метод ближайшего соседа** (*Nearest Neighbor Upsampling*).

Nearest Neighbor

1	2
3	4



1	1	2	2
1	1	2	2
3	3	4	4
3	3	4	4

Input: 2 x 2

Output: 4 x 4

ПОВЫШЕНИЕ РАЗРЕШЕНИЯ: МЕТОД «КРОВАТЬ С ГВОЗДЯМИ»

Суть метода состоит в том, что значения исходной матрицы вставляются в ячейки новой матрицы с увеличенным шагом, а все промежуточные элементы заполняются нулями. Например, при преобразовании матрицы 2×2 в 4×4 каждый элемент исходного массива занимает отдельную позицию, а оставшиеся пиксели становятся нулевыми.

“Bed of Nails”

1	2
3	4



1	0	2	0
0	0	0	0
3	0	4	0
0	0	0	0

Input: 2×2

Output: 4×4

ПОВЫШЕНИЕ РАЗРЕШЕНИЯ: MAX UNPOOLING

При выполнении **max pooling** сеть запоминает индексы элементов, которые были выбраны как максимальные в каждом окне. Во время **max unpooling** значения восстанавливаются в те же позиции, где ранее находились максимумы, а остальные элементы заменяются нулями. В результате восстанавливается пространственная структура признаков, что помогает декодеру точнее локализовать объекты.

Max Pooling

Remember which element was max!

1	2	6	3
3	5	2	1
1	2	2	1
7	3	4	8

Input: 4 x 4



5	6
7	8

Output: 2 x 2



...

Rest of the network

Max Unpooling

Use positions from pooling layer

1	2
3	4

Input: 2 x 2




0	0	2	0
0	1	0	0
0	0	0	0
3	0	0	4

Output: 4 x 4


ПОВЫШЕНИЕ РАЗРЕШЕНИЯ: БИЛИНЕЙНАЯ ИНТЕРПОЛЯЦИЯ

При увеличении изображения новые значения вычисляются по четырём ближайшим пикселям исходной сетки. Сначала выполняется линейная интерполяция по горизонтали, затем — по вертикали. В результате получаются гладкие, непрерывные значения, заполняющие промежутки между исходными пикселями.



ПОВЫШЕНИЕ РАЗРЕШЕНИЯ: TRANSPOSE (UP) CONVOLUTION

При обычной свёртке фильтр «скользит» по изображению, уменьшая размер карты признаков. При транспонированной свёртке операция **разворачивается в обратную сторону**: значения из входной матрицы распределяются на большую область выходной карты с перекрытием, формируя результат большего размера. Таким образом, размер выходной карты увеличивается, а глубина сохраняется.



АРТЕФАКТЫ ТРАНСПОНИРОВАННОЙ СВЁРТКИ

Транспонированная свёртка, хотя и позволяет обучаемо увеличивать разрешение изображений, может порождать характерные «шахматные» артефакты - периодические перепады яркости, которые делают изображение «зернистым» и неестественным.




КЛАССИЧЕСКИЕ АРХИТЕКТУРЫ СЕГМЕНТАЦИИ

Linknet

LinkNet — это архитектура для семантической сегментации, разработанная с целью обеспечить высокую точность при минимальных вычислительных затратах.


Она основана на идее эффективного соединения энкодера и декодера через прямые остаточные связи (skip-connections), которые **суммируются** (add), а не конкатенируются, как в U-Net.




КЛАССИЧЕСКИЕ АРХИТЕКТУРЫ СЕГМЕНТАЦИИ

Linknet vs U-Net

Linknet



U-Net



RECEPTIVE FIELD

Построенные архитектуры сетей, таких как U-Net и LinkNet, основаны на иерархическом извлечении признаков. Для понимания принципов работы подобных моделей необходимо рассмотреть понятие **поля восприятия (receptive field)**, определяющего область исходного изображения, оказывающую влияние на активацию конкретного нейрона. Именно величина поля восприятия определяет, какой объём контекстной информации сеть способна учитывать при сегментации.


Поле восприятия (receptive field) — это область входного изображения, оказывающая влияние на активацию конкретного нейрона в свёрточной нейросети. Чем глубже слой, тем шире его поле восприятия, что позволяет учитывать более глобальный контекст при анализе изображений.

Для последовательности свёрточных слоёв с параметрами:

- k_i — размер ядра i -го слоя,
- s_i — шаг (stride),
- p_i — паддинг (padding),


эффективное поле восприятия r_i на i -м слое вычисляется рекурсивно:

$$r_i = r_{i-1} + (k_i - 1) \prod_{k=1}^{i-1} s_k$$



СВЕРТКА + ПУЛИНГ

Традиционное сочетание **свёртки** и **пулинга** (Conv + Pooling) используется для поэтапного увеличения поля восприятия за счёт снижения пространственного разрешения признаков. Однако это приводит к потере точной пространственной информации, что может негативно влиять на качество сегментации.




ДИЛАТИРОВАННАЯ (РАЗРЕЖЕННАЯ) СВЁРТКА

Дилатированная (разреженная) свёртка (dilated convolution) позволяет расширить поле восприятия без применения пулинга, «вставляя» промежутки между элементами ядра.



Это обеспечивает захват контекста на больших масштабах при сохранении исходного разрешения признаковой карты.

Формально, для дилатированной свёртки с коэффициентом дилатации d и ядром размера k , эффективный размер ядра определяется как:

$$k_{\text{eff}} = k + (k - 1) \times (d - 1)$$



CONV+POOLING VS DILATED CONVOLUTION



На рисунке показано, что обе схемы — и «свёртка + пулинг», и дилатированная свёртка - обеспечивают одинаковое поле восприятия.


Однако в первом случае разрешение признаковой карты уменьшается (объединяются соседние значения), а во втором - сохраняется исходное разрешение за счёт «разрежения» фильтра (вставки промежутков между элементами ядра).

КЛАССИЧЕСКИЕ АРХИТЕКТУРЫ СЕГМЕНТАЦИИ

DeepLab

Архитектура DeepLab основана на модифицированной сети VGG-16, адаптированной для задачи семантической сегментации.

- Полносвязные слои заменены на свёртки 1×1 , что позволяет обрабатывать изображения произвольного размера.
- Вместо пулинга используются **дилатированные (разреженные) свёртки**, которые сохраняют пространственное разрешение карты признаков и одновременно увеличивают поле восприятия.
- На выходе применяется **билинейное повышение разрешения** (upsampling) для восстановления исходного размера изображения.




КЛАССИЧЕСКИЕ АРХИТЕКТУРЫ СЕГМЕНТАЦИИ

FPN (Feature Pyramid Networks)

Архитектура Feature Pyramid Network используется для эффективного **объединения признаков разных уровней** глубины нейросети.

- Нижние уровни содержат высокое пространственное разрешение, но низкую семантическую выразительность.
- Верхние уровни, наоборот, обладают глубокими семантическими признаками, но низким разрешением.
- FPN объединяет их через обратные (up) и добавочные (add) связи, создавая пирамиду признаков, где каждая карта сочетает детали и контекст.

Благодаря этому сеть может одинаково хорошо обнаруживать и сегментировать объекты разных размеров, что делает FPN важным компонентом современных моделей (Mask R-CNN, RetinaNet и др.).




КЛАССИЧЕСКИЕ АРХИТЕКТУРЫ СЕГМЕНТАЦИИ

HRNet (High-Resolution Network)

Архитектура HRNet **сохраняет высокое разрешение признаков** на протяжении всего процесса обработки, в отличие от большинства сетей, которые последовательно уменьшают разрешение и восстанавливают его на этапе апсемплинга.

- Сеть параллельно обрабатывает признаки на нескольких масштабах (1×, 2×, 4× и т. д.).
- Между этими масштабами происходит постоянный обмен информацией (skip-связи между уровнями).
- Это позволяет эффективно сочетать детальные и контекстные признаки, обеспечивая высокую точность сегментации и локализации границ объектов.

HRNet часто используется в задачах сегментации, распознавания поз и ключевых точек, где важно сохранить пространственную точность.



МЕТРИКИ В СЕГМЕНТАЦИИ

Pixel Accuracy (PA)

Доля правильно классифицированных пикселей:

Простая, но чувствительна к дисбалансу классов (например, много фона).

$$PA = \frac{TP + TN}{TP + TN + FP + FN}$$

Dice Coefficient (F1-мера для масок)

Мера сходства двух множеств:

Более чувствителен к малым объектам, чем IoU.

$$Dice = \frac{2|A_{pred} \cap A_{true}|}{|A_{pred}| + |A_{true}|}$$

Intersection over Union (коэфф. Жаккара)

Отношение пересечения предсказанной и истинной областей к их объединению:

Основная метрика для оценки качества сегментации.

$$IoU = \frac{|A_{pred} \cap A_{true}|}{|A_{pred} \cup A_{true}|}$$

Hausdorff Distance (HD, расстояние Хаусдорфа)

Измеряет максимальное расстояние между границами истинной и предсказанной масок. Применяется в задачах, где важна точность контуров (например, медицинская анатомия).

В instance segmentation и panoptic segmentation также используются **детекционные** метрики (mAP, F1, Precision, Recall), однако в semantic segmentation нет отдельных объектов, есть только маски классов, поэтому такие метрики уже не применимы напрямую.

ФУНКЦИИ ПОТЕРЬ В ЗАДАЧЕ СЕГМЕНТАЦИИ

В задачах **классификации** и **детекции** мы уже знакомы с классическими функциями потерь — такими как Cross-Entropy, Focal Loss, направленными на корректную классификацию объектов.

Однако в сегментации важна не только правильная классификация каждого пикселя, но и **совпадение формы и границ объектов**. Поэтому используются специальные типы функций потерь:

Пиксельно-ориентированные функции потерь (distribution-based)

минимизируют ошибку классификации каждого пикселя

- Weighted Binary Cross-Entropy (WBCE) — компенсирует дисбаланс классов, повышая вес малочисленных областей.
- Focal Loss — фокусируется на трудных пикселях, снижая вклад лёгких примеров.

Функции потерь на перекрытие областей (region-based)

оптимизируют совпадение предсказанной и истинной масок


- Dice Loss — максимизирует коэффициент перекрытия (аналог F1-меры).
- Tversky Loss — обобщает Dice Loss, позволяя по-разному штрафовать ложные срабатывания (FP) и пропуски (FN), что полезно при дисбалансе классов.
- Generalized IoU Loss — учитывает взаимное расположение областей, полезен при частичном пересечении или смещении объектов.

Функции потерь на расстояниях (boundary-based)

минимизируют ошибки по форме и контуру объекта

- Boundary Loss — измеряет расстояние между границами истинной и предсказанной масок, улучшает локализацию и чёткое выделение контуров

ФУНКЦИИ ПОТЕРЬ В ЗАДАЧЕ СЕГМЕНТАЦИИ



ВЗВЕШЕННАЯ БИНАРНАЯ КРОСС-ЭНТРОПИЙНАЯ ФУНКЦИЯ ПОТЕРЬ


Проблема дисбаланса классов

Рассмотрим задачу сегментации экземпляров чаек:

Левое изображение — исходное фото;

Правое изображение — предсказанная маска сегментации.

Сеть корректно классифицировала большинство фоновых пикселей, но пропустила большую часть объекта. Так как фон занимает большую часть изображения, итоговая потеря по обычной *BCE* (Binary Cross-Entropy) оказывается низкой, и модель ошибочно считает свою работу успешной.



Чтобы компенсировать дисбаланс, в формулу вводится **весовой коэффициент α** , который усиливает вклад менее представленного класса:

$$L_{WBCE} = -\alpha y \log(p) - (1 - \alpha)(1 - y) \log(1 - p)$$

где

- y — истинная метка (0 или 1),
- p — вероятность принадлежности к классу 1,
- α — вес, отражающий относительное количество пикселей класса.

Если объект занимает меньшую часть изображения, то α выбирается больше 0.5, чтобы модель сильнее штрафовалась за ошибки при распознавании редкого класса (объекта).

ФОКАЛЬНАЯ ФУНКЦИЯ ПОТЕРЬ

Focal Loss — улучшенная версия бинарной кросс-энтропии, предназначенная для решения проблемы дисбаланса классов и смещения к лёгким примерам. Добавляется параметр γ (гамма), который усиливает вклад трудных для классификации пикселей и уменьшает потери для лёгких примеров:


$$L_{Focal} = -\alpha(1 - p_t)^\gamma \log(p_t)$$

где p_t — вероятность правильного класса, α компенсирует дисбаланс классов, γ управляет степенью фокусировки на сложных случаях.

При $\gamma=0$ функция эквивалентна обычной BCE.

При $\gamma>0$ потери для легко классифицируемых пикселей уменьшаются, а для сложных — увеличиваются.

В сегментации Focal Loss позволяет модели уделять больше внимания пикселям на границах объектов, где вероятность ошибки максимальна, и тем самым улучшает качество выделения контуров.



Кривая фокальных потерь для различных параметров гамма

DICE LOSS (ПОТЕРЯ НА ПЕРЕКРЫТИЕ ОБЛАСТЕЙ)

Dice Loss — функция потерь, основанная на метрике Dice Coefficient (F1-score). Она измеряет степень перекрытия предсказанной и истинной масок и особенно эффективна при дисбалансе классов или малых объектах.


$$Dice = \frac{2|A_{pred} \cap A_{true}|}{|A_{pred}| + |A_{true}|}, \quad L_{Dice} = 1 - Dice$$

Значения близкие к 1 означают полное совпадение масок.

Dice Loss оптимизирует пересечение областей, а не отдельные пиксели.

Часто используется совместно с Cross-Entropy для улучшения стабильности обучения.

В сегментации позволяет модели лучше выделять мелкие объекты и точнее восстанавливать границы, где ошибка пиксельной классификации не всегда отражает реальное качество маски.



TVERSKY LOSS (ОБОБЩЁННАЯ DICE LOSS)

Tversky Loss – это обобщение Dice Loss, позволяющее регулировать соотношение штрафов за ложноположительные (FP) и ложноотрицательные (FN) пиксели. Это особенно важно при дисбалансе классов и при сегментации мелких объектов.

$$Tversky = \frac{|A_{pred} \cap A_{true}|}{|A_{pred} \cap A_{true}| + \alpha|FP| + \beta|FN|}, \quad L_{Tversky} = 1 - Tversky$$

Параметры α и β задают вес ложных срабатываний и пропусков.

При $\alpha=\beta=0.5$ формула совпадает с Dice Loss.

Если $\beta>\alpha$, модель сильнее штрафует пропущенные пиксели (FN) – полезно при малых объектах.

В сегментации Tversky Loss улучшает баланс между полнотой и точностью, повышая качество масок при сложных границах и неравномерных классах.

ПОТЕРЯ ГРАНИЦ (BOUNDARY LOSS)


Boundary Loss применяется в случаях, когда региональные функции потерь (такие как Dice или Cross-Entropy) становятся неустойчивыми из-за сильного дисбаланса классов. Вместо сравнения площадей перекрытия, Boundary Loss оценивает расстояние между истинными и предсказанными границами объектов.

$$L_{\text{boundary}} \propto \int_{\Omega} \phi_{GT}(x) p(x) dx$$


где $\phi_{GT}(x)$ — расстояние от точки до истинного контура.

Учитывает точность формы и положения границ, а не только совпадение областей. Эффективна при тонких структурах, мелких объектах и дисбалансе классов. Часто используется в сочетании с Dice Loss для улучшения качества контуров.

Идея в том, что вместо интеграла по площади (Dice) используется интеграл по пограничной области, что позволяет модели учиться точнее воспроизводить контуры объектов.



(a) Differential



(b) Integral

Взаимосвязь между дифференциальным и интегральным подходами к оценке изменения (вариации) границ

ПОЧЕМУ ОДНОЙ ФУНКЦИИ ПОТЕРЬ НЕДОСТАТОЧНО

- Cross-Entropy / Focal Loss

Отвечают только за корректную классификацию пикселей (правильно ли пиксель относится к классу «объект» или «фон»). Но они не следят за формой объекта, не контролируют границы и не измеряют истинное совпадение масок.

- Dice / IoU Loss

Отвечают за перекрытие масок. Но они неустойчивы к шуму, и могут давать хорошие значения даже если границы объекта предсказаны плохо

- Boundary Loss


Отвечает за точность границ. Но если использовать только его - сеть может рисовать «правильную форму», но при этом ошибаться в классификации пикселей.

Проблема: Каждая функция потерь оптимизирует только одну часть задачи, а сегментация - это одновременно: классификация пикселей, восстановление формы, корректные границы, учёт дисбаланса, устойчивость к шуму. Одна потеря не может обеспечить всё сразу.


Поэтому в современных архитектурах всё чаще используют **комбинированные функции потерь**, где итоговый лосс - это сумма или взвешенное сочетание нескольких компонентов. Такой подход позволяет уравновесить цели модели и улучшить обучение.

КОМБИНИРОВАННЫЕ ФУНКЦИИ ПОТЕРЬ


BCE





Dice loss



BCE + Dice loss




BCE + Dice loss
+ Focal loss



МНОГОЗАДАЧНОЕ ОБУЧЕНИЕ (MULTI-TASK LEARNING)

Объединение нескольких критериев качества превращает процесс обучения в решение нескольких подзадач одновременно: одна подзадача отвечает за классификацию пикселей, другая - за форму объекта, третья - за его границы и т. д. Это напрямую приводит к понятию **многозадачного обучения** (Multi-task learning), когда модель обучается выполнять сразу несколько связанных задач, используя общий энкодер. В многозадачной архитектуре итоговая функция потерь формируется как **комбинация лоссов** всех ветвей сети. Подобный подход позволяет улучшить качество сегментации, повысить устойчивость модели и обеспечить более богатое обучение признаков.



Модели, совмещающие детекцию и сегментацию

Mask R-CNN, YOLACT / YOLACT++, PANet, Detectron2 Cascade Mask R-CNN

Модели, совмещающие сегментацию и классификацию

U-Net + Classification Head, HRNet + Classification Branch, DeepLab + Auxiliary Classifier (DeepLab v3/v3+)

Модели, совмещающие сегментацию и предсказание границ

BDCN (Bi-Directional Cascade Network), DeepLab + Edge Loss

Модели, совмещающие сегментацию и глубину / нормали / геометрию сцены

SegNet + Depth Branch, MTL-ResNet, NYU v2 multi-task models

Модели, совмещающие несколько сегментационных задач одновременно

UNet++ Multi-task, Multi-task Attention U-Net



Управление данными и искусственный интеллект
Лекция по дисциплине:
“Глубокое обучение в компьютерном зрении”



Российский университет
дружбы народов

КОМПЛЕКСНЫЕ МЕТОДЫ СЕГМЕНТАЦИИ ИЗОБРАЖЕНИЙ: ФУНКЦИИ ПОТЕРЬ, АРХИТЕКТУРЫ И МНОГОЗАДАЧНОЕ ОБУЧЕНИЕ

Преподаватели: Перчихин Олег Игоревич
Федоренко Анастасия Олеговна